LAPORAN TUGAS BIG DATA — PERTEMUAN 4

Kualitas Data dan Data Preprocessing: Kasus Data Transaksi E-Commerce

Nama: [Nama Mahasiswa] | NIM: [NIM]

I. Tujuan

Mengidentifikasi masalah kualitas data, melakukan profiling, menangani nilai kosong dan duplikat, memperbaiki tipe data, serta membandingkan dataset sebelum dan sesudah dibersihkan, dengan menerapkan prinsip amanah, tabayyun, privasi, dan tanggung jawab (AIK).

II. Deskripsi Kasus

Sebuah toko daring mengumpulkan data transaksi dari aplikasi. Sebelum dipakai untuk menghitung penjualan dan membuat dashboard, ditemukan harga kosong, transaksi berulang, penulisan kota yang berbeda-beda, dan kolom harga tersimpan sebagai teks. Dataset dasar berisi 7 baris (kolom: transaction_id, product, category, quantity, price, city). Pada Bagian C dataset diperluas menjadi 18 baris (11 baris tambahan berupa data latihan buatan, tanpa data pribadi nyata).

III. Identifikasi Masalah Kualitas Data (Bagian A)

1–2. Masalah dan dimensi kualitas data

No	Masalah (contoh data)	Dimensi	Dampak	Tindakan perbaikan
1	Harga kosong pada TR003 (Keyboard); pada dataset diperluas juga TR010 (SSD)	Kelengkapan	Nilai transaksi tidak dapat dihitung; total penjualan terlalu rendah	Tandai, pisahkan, verifikasi ke sumber; tidak diisi rata-rata
2	Baris TR002 muncul dua kali dengan isi identik	Keunikan	Penjualan terhitung ganda (+Rp300.000)	Hapus duplikat identik, simpan 1 salinan, catat di log
3	Kota ditulis Jakarta, jakarta, DKI Jakarta (juga " Jakarta ", JAKARTA, depok, bekasi)	Konsistensi	Satu kota terpecah menjadi beberapa kategori; hasil groupby dan dashboard menyesatkan	Strip spasi, abaikan huruf besar/kecil, kamus kanonik
4	Kolom price bertipe teks ("7500000"; juga "Rp 450.000")	Validitas	Tidak bisa dijumlah/dirata-rata; 2 * "150000" menghasilkan "150000150000"	Bersihkan format, ubah ke numerik, cek NaN baru
5	ID sama tetapi isi berbeda (TR012: quantity 1 dan 2)	Akurasi / Keunikan	Tidak diketahui mana yang benar; risiko salah hitung	Karantina dan verifikasi (bukan dedup otomatis)
6	Tidak ada kolom tanggal/waktu transaksi	Ketepatan waktu	Tidak dapat menilai kebaruan data atau membuat tren periodik	Usulkan penambahan kolom timestamp pada sumber data

3. Aturan penanganan nilai kosong. (a) Periksa sumber asli (sistem pesanan/katalog) untuk harga pada tanggal transaksi. (b) Jika ada rujukan resmi, lengkapi dan catat sumbernya. (c) Jika tidak ada, jangan isi: tandai sebagai perlu verifikasi, pisahkan dari data siap analisis, dan laporkan jumlahnya. (d) Tidak dihapus permanen. Alasannya, harga sangat bergantung pada produk (Laptop Rp7.500.000 vs Mouse Rp150.000), sehingga rata-rata semua produk tidak mewakili harga Keyboard, mengubah total tanpa dasar, dan menyembunyikan ketidakpastian.

4. Menentukan duplikat yang benar-benar sama. Dua baris dianggap transaksi yang sama bila seluruh kolom identik (ID, produk, kategori, jumlah, harga, kota) dan, pada data nyata, dikuatkan oleh timestamp, ID pesanan, atau referensi pembayaran yang sama. Jika ID sama tetapi isi berbeda (TR012), itu konflik dan bukan duplikat identik, sehingga harus diverifikasi. Jika isi sama tetapi ID berbeda, bisa jadi pembelian berulang yang sah sehingga tidak boleh dihapus otomatis.

5. Aturan standarisasi. Kota: hapus spasi berlebih, samakan huruf (Title Case), petakan "DKI Jakarta" dan "jakarta" ke "Jakarta" lewat kamus kanonik; kota lain (Bekasi, Depok, Cikarang, dst.) tidak digabung tanpa dasar. price: numerik (Rupiah), hapus awalan "Rp" dan titik ribuan, harus > 0, periksa NaN baru setelah konversi. quantity: bilangan bulat > 0.

6. Risiko jika langsung dipakai. Pada eksperimen ini hitungan naif menghasilkan Rp20.855.000 dibanding Rp19.505.000 pada data bersih (selisih Rp1.350.000), dan kota terbaca sebagai 13 label alih-alih 5. Dampaknya: penjualan salah lapor, ranking kota keliru, dashboard dan keputusan stok/promosi/target menyesatkan, serta hilangnya kepercayaan pada tim data.

7. Penerapan AIK. Amanah: angka dilaporkan apa adanya, tidak merekayasa total, dan setiap perubahan dicatat dalam cleaning log. Tabayyun: data kosong, duplikat, dan konflik diverifikasi ke sumber sebelum disimpulkan (sejalan dengan perintah memeriksa dengan teliti suatu kabar, QS. Al-Hujurat: 6), bukan ditebak. Privasi: hanya memakai data latihan tanpa nama, alamat, atau kontak pelanggan; jika data nyata dipakai, harus seizin pemilik dan dianonimkan. Tanggung jawab: tidak menghapus data tanpa alasan, menyatakan keterbatasan hasil, dan menyediakan notebook agar dapat diaudit ulang.

IV. Aturan Cleaning dan Cleaning Log

Urutan: duplikat identik, perbaikan tipe data, standarisasi kota, karantina ID konflik, pemisahan nilai kosong, lalu pembentukan data siap analisis. Setiap keputusan dicatat berikut.

Langkah	Aksi	Baris	Alasan
1	Hapus duplikat identik (simpan 1 salinan)	1	Seluruh kolom sama persis; menghitung dua kali akan menggandakan penjualan
2a	Bersihkan format harga 'Rp x.xxx.xxx' lalu ubah ke angka	1	Nilai valid tetapi berformat teks; to_numeric langsung akan menghasilkan NaN palsu
2b	Ubah price dan quantity menjadi numerik	17	Perhitungan total memerlukan tipe angka; quantity * teks akan mengulang string, bukan mengalikan
3	Standarisasi kota (trim, huruf, 'DKI Jakarta' -> 'Jakarta')	7	Satu kota tidak boleh terpecah menjadi beberapa kategori saat groupby
4	Karantina transaksi ber-ID sama tetapi isi berbeda ['TR012']	2	Tidak dapat dipastikan mana yang benar; perlu tabayyun ke sumber, bukan ditebak
5	Pisahkan baris dengan price/quantity kosong (tanpa imputasi)	2	Harga bergantung produk; rata-rata tidak berdasar dan menyembunyikan ketidakpastian
6	Bentuk data siap analisis dan hitung total = quantity x price	13	Hanya baris lengkap, unik, dan valid yang dihitung

V. Hasil Sebelum dan Sesudah Cleaning

A. Pipeline dasar (7 baris)

Tahap	Jumlah baris
Baris sebelum cleaning	7
Setelah deduplikasi	6
Siap analisis (harga TR003 kosong dipisahkan)	5
Total penjualan data dasar	Rp11.350.000

B. Dataset diperluas (18 baris): ringkasan masalah kualitas

Jenis masalah	Sebelum	Sesudah
Kelengkapan: price kosong	2	0
Kelengkapan: quantity kosong	0	0
Keunikan: baris duplikat identik	1	0
Keunikan: ID ganda dengan isi berbeda (konflik)	1	0
Konsistensi: penulisan kota tidak baku	7	0
Validitas: price bertipe teks (bukan numerik)	1	0
Validitas: price teks tak terbaca sebagai angka	1	0
Validitas: quantity/price <= 0	0	0

Jenis masalah	Sebelum	Sesudah
TOTAL	**13**	**0**

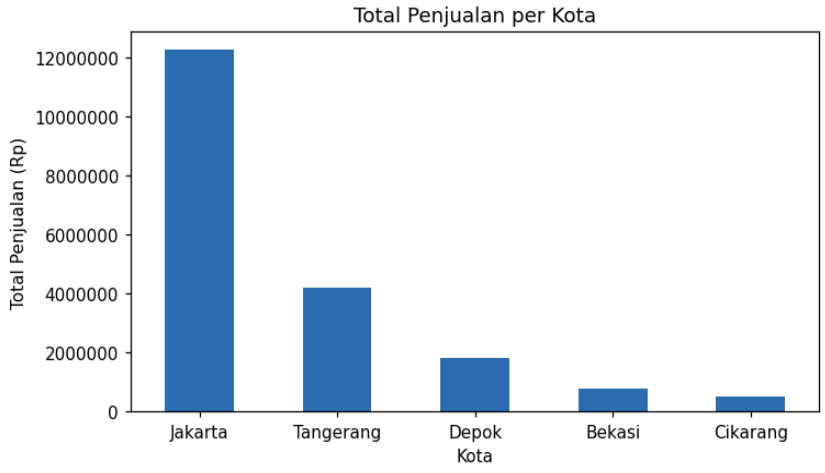
Jumlah baris: awal **18** → setelah deduplikasi **17** → siap analisis **13**.

C. Data siap analisis

transaction_id	product	category	quantity	price	total	city
TR001	Laptop	Elektronik	1	Rp7.500.000	Rp7.500.000	Jakarta
TR002	Mouse	Elektronik	2	Rp150.000	Rp300.000	Bekasi
TR004	Monitor	Elektronik	1	Rp2.500.000	Rp2.500.000	Jakarta
TR005	Headset	Aksesori	3	Rp250.000	Rp750.000	Jakarta
TR006	Webcam	Aksesori	1	Rp300.000	Rp300.000	Cikarang
TR007	Flashdisk	Aksesori	4	Rp85.000	Rp340.000	Bekasi
TR008	Printer	Elektronik	1	Rp1.800.000	Rp1.800.000	Depok
TR009	Tas Laptop	Aksesori	2	Rp175.000	Rp350.000	Jakarta
TR011	Speaker	Elektronik	2	Rp450.000	Rp900.000	Jakarta
TR013	Mouse Pad	Aksesori	5	Rp50.000	Rp250.000	Jakarta
TR014	Hub USB	Aksesori	1	Rp120.000	Rp120.000	Bekasi
TR015	Kabel HDMI	Aksesori	3	Rp65.000	Rp195.000	Cikarang
TR016	Smartphone	Elektronik	1	Rp4.200.000	Rp4.200.000	Tangerang

D. Total penjualan per kota (groupby)

Kota	Total penjualan	Kontribusi
Jakarta	Rp12.250.000	62.8%
Tangerang	Rp4.200.000	21.5%
Depok	Rp1.800.000	9.2%
Bekasi	Rp760.000	3.9%
Cikarang	Rp495.000	2.5%
Total	**Rp19.505.000**	**100%**



Gambar 1. Total penjualan per kota (data siap analisis).

VI. Analisis Hasil

Baris yang tidak masuk analisis dan alasannya

ID	Produk	Qty	Harga	Kota	Alasan
TR002	Mouse	2	Rp150.000	Bekasi	Duplikat identik (1 salinan sudah dipakai)

ID	Produk	Qty	Harga	Kota	Alasan
TR012	Router	1	Rp650.000	Bogor	ID sama, isi berbeda: perlu verifikasi
TR012	Router	2	Rp650.000	Bogor	ID sama, isi berbeda: perlu verifikasi
TR003	Keyboard	1	(kosong)	Depok	Harga kosong: perlu verifikasi, tidak diimputasi
TR010	SSD	1	(kosong)	Bandung	Harga kosong: perlu verifikasi, tidak diimputasi

Tidak ada baris yang dihapus tanpa alasan: baris kosong dan konflik hanya ditahan dari perhitungan sampai diverifikasi, sedangkan duplikat identik dibuang karena informasinya sudah terwakili satu salinan.

Temuan dari hasil program

1. Dataset awal 18 baris; hanya 13 baris (72%) layak dihitung. 5 baris dikeluarkan atau ditahan karena duplikat, konflik, atau harga kosong.

2. Total masalah kualitas turun dari 13 menjadi 0 setelah preprocessing.

3. Total penjualan bersih Rp19.505.000, sedangkan hitungan naif Rp20.855.000 (selisih Rp1.350.000) akibat duplikat, baris konflik, dan harga 'Rp 450.000' yang gagal terbaca.

4. Jakarta adalah kota penjualan terbesar (Rp12.250.000; 62.8% dari total).

5. Tanpa standarisasi, kota terbaca sebagai 13 label berbeda; sesudahnya hanya 5 kota unik.

6. Elektronik menyumbang Rp17.200.000 dan Aksesori Rp2.305.000.

7. Transaksi tunggal terbesar: TR001 (Laptop) senilai Rp7.500.000.

8. 2 transaksi harga kosong dan 2 baris konflik ID (TR012) perlu diverifikasi; penjualan sebenarnya kemungkinan lebih tinggi dari angka bersih ini.

VII. Kesimpulan

Preprocessing menurunkan masalah kualitas data dari 13 menjadi 0, dengan 13 dari 18 baris layak dianalisis dan total penjualan terverifikasi Rp19.505.000. Nilai yang tidak dapat dipastikan (harga kosong, ID konflik) tidak ditebak tetapi ditandai untuk diverifikasi, sehingga laporan penjualan dapat dipertanggungjawabkan. Kualitas data adalah prasyarat analisis: data yang belum bersih menghasilkan angka yang tampak meyakinkan tetapi keliru. Notebook terlampir memuat seluruh kode, keluaran, dan cleaning log agar hasil dapat direproduksi dan diaudit.