BIG DATA

PERTEMUAN 4 — TUGAS KASUS DAN PROGRAMMING

Topik: Kualitas Data dan Data Preprocessing

Alokasi: 50 menit analisis kasus dan 50 menit programming.

Tujuan: Mengidentifikasi masalah kualitas data, melakukan profiling, menangani nilai kosong dan duplikat, memperbaiki tipe data, serta membandingkan dataset sebelum dan sesudah dibersihkan.

BAGIAN A — TUGAS ANALISIS KASUS

Kasus: Data Transaksi E-Commerce yang Belum Bersih

Sebuah toko daring mengumpulkan data transaksi dari aplikasi. Sebelum data digunakan untuk menghitung penjualan dan membuat dashboard, tim menemukan harga kosong, data transaksi berulang, format nama kota berbeda, dan kolom harga tersimpan sebagai teks. Mahasiswa berperan sebagai analis data yang harus memeriksa dan menyiapkan dataset secara bertanggung jawab.

Dataset contoh:
transaction_id, product, category, quantity, price, city
TR001, Laptop, Elektronik, 1, 7500000, Jakarta
TR002, Mouse, Elektronik, 2, 150000, Bekasi
TR003, Keyboard, Elektronik, 1, [kosong], Depok
TR004, Monitor, Elektronik, 1, 2500000, DKI Jakarta
TR002, Mouse, Elektronik, 2, 150000, Bekasi
TR005, Headset, Aksesori, 3, 250000, jakarta

Pertanyaan analisis kasus:

1. Identifikasi minimal empat masalah kualitas data.

2. Hubungkan setiap masalah dengan dimensi kualitas data: kelengkapan, akurasi, konsistensi, validitas, keunikan, atau ketepatan waktu.

3. Tentukan aturan penanganan nilai kosong dan jelaskan alasannya. Jangan mengisi nilai tanpa dasar.

4. Jelaskan cara menentukan apakah baris duplikat benar-benar transaksi yang sama.

5. Tentukan aturan standarisasi nama kota dan tipe data price serta quantity.

6. Jelaskan risiko jika data yang belum bersih langsung digunakan untuk menghitung penjualan.

7. Jelaskan penerapan amanah, tabayyun, privasi, dan tanggung jawab sesuai AIK.

Luaran: jawaban 1–2 halaman, dilengkapi tabel masalah, dampak, dan tindakan perbaikan.

BAGIAN B — TUGAS PROGRAMMING PYTHON

Gunakan Google Colab atau Jupyter Notebook dan library pandas. Dataset dibuat langsung melalui kode berikut sehingga tidak perlu mengunduh file eksternal.

Langkah 1 — Membuat dataset

```
import pandas as pd
import matplotlib.pyplot as plt

data = {
    "transaction_id": ["TR001", "TR002", "TR003", "TR004",
                       "TR002", "TR005", "TR006"],
    "product": ["Laptop", "Mouse", "Keyboard", "Monitor",
                "Mouse", "Headset", "Webcam"],
    "category": ["Elektronik", "Elektronik", "Elektronik",
                 "Elektronik", "Elektronik", "Aksesori", "Aksesori"],
    "quantity": [1, 2, 1, 1, 2, 3, 1],
    "price": ["7500000", "150000", None, "2500000",
              "150000", "250000", "300000"],
    "city": ["Jakarta", "Bekasi", "Depok", "DKI Jakarta",
             "Bekasi", "jakarta", "Cikarang"]
}
df = pd.DataFrame(data)
print(df)
```

Langkah 2 — Data profiling

```
print("Ukuran dataset:", df.shape)
print("\nTipe data:")
print(df.dtypes)
print("\nNilai kosong:")
print(df.isnull().sum())
print("\nJumlah baris duplikat:", df.duplicated().sum())
print("\nStatistik:")
print(df.describe(include="all"))
```

Langkah 3 — Periksa dan tangani duplikat identik

```
print(df[df.duplicated(keep=False)])
df_clean = df.drop_duplicates().copy()
```

Langkah 4 — Perbaiki tipe data

```
df_clean["price"] = pd.to_numeric(df_clean["price"], errors="coerce")
df_clean["quantity"] = pd.to_numeric(df_clean["quantity"], errors="coerce")
print(df_clean.dtypes)
print(df_clean.isnull().sum())
```

Langkah 5 — Standarisasi kota

```
df_clean["city"] = df_clean["city"].replace({
    "jakarta": "Jakarta",
    "DKI Jakarta": "Jakarta"
})
print(df_clean["city"].value_counts())
```

Langkah 6 — Tandai nilai kosong

Jangan langsung mengisi harga kosong dengan rata-rata tanpa alasan. Tampilkan baris yang perlu diverifikasi dan pisahkan dari data siap analisis.

```
missing_price = df_clean[df_clean["price"].isna()]
print("Baris perlu verifikasi:")
print(missing_price)

df_ready = df_clean.dropna(subset=["price", "quantity"]).copy()
```

Langkah 7 — Hitung nilai transaksi

```
df_ready["total"] = df_ready["quantity"] * df_ready["price"]
print(df_ready[["transaction_id", "product", "quantity",
                "price", "total", "city"]])
print("Total penjualan:", df_ready["total"].sum())
```

Langkah 8 — Bandingkan sebelum dan sesudah cleaning

```
print("Baris sebelum cleaning:", len(df))
print("Baris setelah deduplikasi:", len(df_clean))
print("Baris siap analisis:", len(df_ready))
print("Nilai kosong awal:\n", df.isnull().sum())
print("Nilai kosong data siap analisis:\n", df_ready.isnull().sum())
```

BAGIAN C — PENGEMBANGAN

1. Tambahkan minimal 10 baris data realistis, termasuk sedikitnya satu nilai kosong dan satu format kota tidak konsisten.

2. Buat ringkasan jumlah masalah kualitas data sebelum dan sesudah preprocessing.

3. Hitung total penjualan per kota menggunakan groupby.

4. Buat satu grafik batang total penjualan per kota.

5. Jelaskan baris yang tidak masuk analisis dan alasannya.

6. Tuliskan minimal lima temuan dari hasil program.

7. Catat setiap keputusan cleaning dan hindari menghapus data tanpa alasan.

Contoh analisis kota dan visualisasi

```
sales_by_city = df_ready.groupby("city")["total"].sum().sort_values(ascending=False)
print(sales_by_city)

sales_by_city.plot(kind="bar")
plt.title("Total Penjualan per Kota")
plt.xlabel("Kota")
plt.ylabel("Total Penjualan")
plt.tight_layout()
plt.show()
```

BAGIAN D — FORMAT PENGUMPULAN

Laporan PDF memuat tujuan, deskripsi kasus, identifikasi masalah, aturan cleaning, hasil sebelum-sesudah, tabel/grafik, analisis, dan kesimpulan. Lampirkan notebook .ipynb atau tautan Google Colab yang dapat diakses dosen.

Nama file: Tugas_BigData_Pertemuan4_Nama_NIM.pdf dan Praktikum_BigData_Pertemuan4_Nama_NIM.ipynb. Jangan gunakan data pribadi nyata; gunakan data latihan atau data yang telah diizinkan.

RUBRIK PENILAIAN

Analisis kasus 25% · Ketepatan coding 30% · Keputusan cleaning dan dokumentasi 20% · Analisis hasil dan visualisasi 15% · Kerapian laporan serta penerapan etika data/AIK 10%.